

本文提出的基于时序周期与轻量卷积网络的温室环境变量预测模型（Greenhouse Environmental Variable Prediction Model Based on Temporal Periodicity and Lightweight Convolutional Networks）结构如图 1 所示。该模型首先通过多尺度序列生成模块，将原始的多变量时序数据下采样以捕捉不同时间粒度的模式。接着，尺度内一维时间序列到二维图像转换模块利用快速傅里叶变换（Fast Fourier Transform, FFT）分析序列周期性，并将 1D 序列重塑为 2D 图像以显式建模周期变化。为了便于高效处理，变量-尺度解耦重构模块对数据维度进行重组。随后，模型采用 2D 深度可分离卷积模块，以轻量化的方式提取 2D 图像中的深层特征并融合多变量信息。最后，多尺度特征融合模块将来自不同尺度的预测信息进行聚合，输出最终的温室环境变量预测结果。

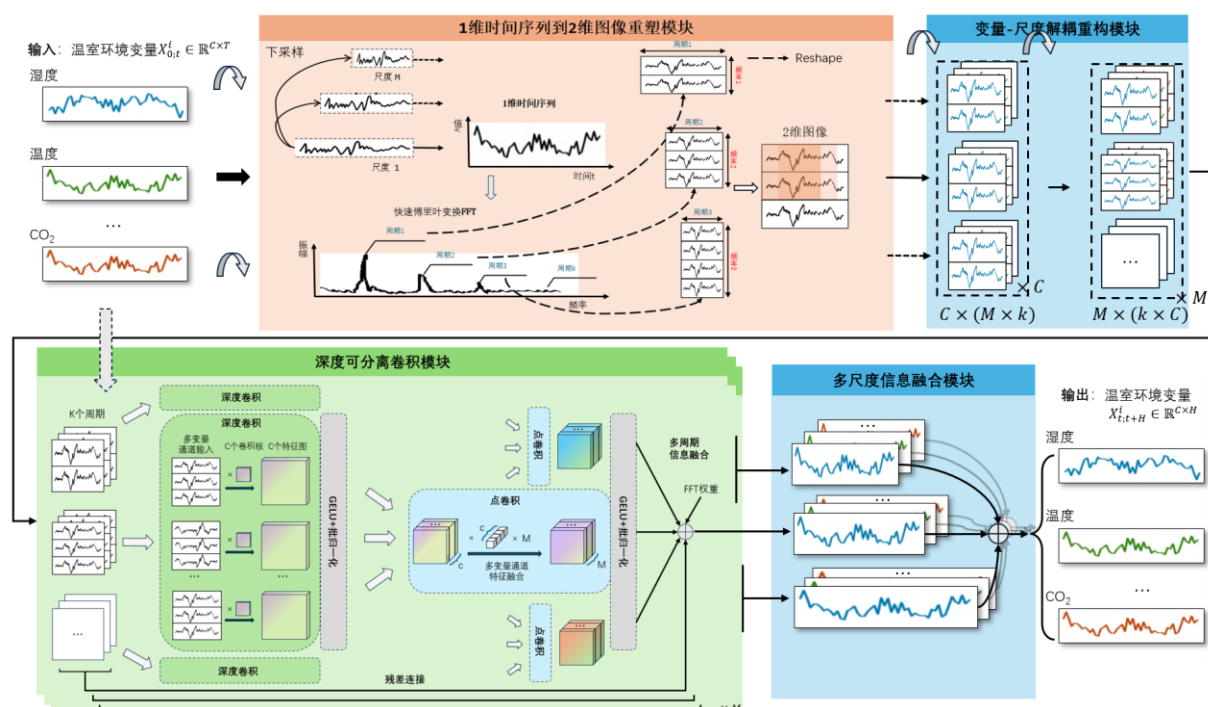


图 1 基于 1 维时间序列到 2 维图像转换和深度可分离卷积网络的多变量智能温室种植环境调控模型结构图

模型的输入为智能温室中的多变量时间序列数据，其中包括详细的温室内环境参数、作物生长相关指标及设备运行状态，例如空气湿度、空气温度、 CO_2 浓度、灌溉、通风、幕布控制等，适用于本方案中温室气候建模研究方向。输入的时间序列虽然存在空缺值，但是确保了其时间戳尺度上的对应，便于本模型的训练与预测。

Module 1: 一维时间序列到二维图像转换

步骤一：多变量共同生成多尺度

针对于温室环境时间序列数据多尺度的特点，模型首先通过下采样操作，将原始长序列分段并聚合为多个不同时间粒度（尺度）的子序列。例如，从每分钟数据生成每小时、每日尺度的序列，以捕捉环境在不同时间粒度下的变化模式。

同时，为了便于后续模型针对所有变量进行统一的处理，这里需要对所有变量进行一致

的多尺度生成，也就是要求我们获得所有变量的统一尺度，由于数据具有较强的相关性及良好的对应关系，这里选择对原始序列进行平均池化。针对所有的变量 $X_{0:t}^i \in \mathbb{R}^{C \times T}$ ，其中 T 表示序列长度， C 表示变量数量，输入时间序列 x_0 跨 M 尺度使用步长为 2 的卷积操作进行逐步下采样，生成多尺度集 $\mathcal{X}_{int} = \{x_0, \dots, x_M\}$ ，其中 $x_m \in \mathbb{R}^{C \times \lfloor \frac{T}{2^m} \rfloor}$ ，具体过程如下公式所示：

$$x_m = \text{Conv}(x_{m-1}, \text{stride} = 2), m = 1, \dots, M \quad (1)$$

步骤二：周期性识别

时间序列表现出复杂的多尺度和多周期动力学。多分辨率分析 (Harti, 1993) 将时间序列建模为频域中各种周期成分的复合体。模型引入多分辨率时间图像，基于频谱分析将 1D 多尺度时间序列转换为 2D 图像，同时保留原始数据。这捕捉了时间和频域中的复杂模式，使得卷积方法能够高效地提取时间模式，并增强任务的通用性。具体如下图 2 所示。

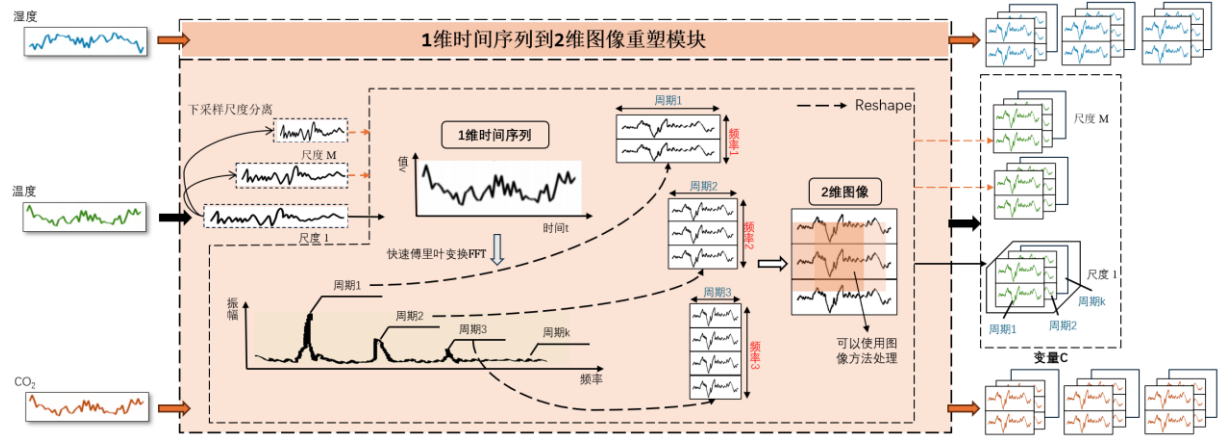


图 2. 1 维时间序列到 2 维图像重塑模块图

在这里，首先对每一尺度下的多变量序列 \mathcal{X}_{int} ，进行傅里叶变换 (FFT) 分析，识别出该尺度下最显著的、共享的周期性成分，将其转换成 $(M + 1) \times K$ 二维图像。这将提供将 1D 序列转换为 2D 张量的依据。根据识别出的周期，将每个尺度下的 1D 多变量序列重塑为 2D 张量。具体而言，对最大的尺度序列的所有变量 x_M^l 首先进行归一化，然后加和得到多变量总的数值特征 X_M^l ，最后对其应用快速傅里叶变换 (FFT)，并选择具有最高幅度的前 K 频率。

$$X_M^l = \sum_{i=1}^C \text{LayerNorm}(x_M^i) \quad (2)$$

$$A, \{f_1, \dots, f_K\}, \{p_1, \dots, p_K\} = \text{FFT}(X_M^l) \quad (3)$$

其中 $A = \{A_{f_1}, \dots, A_{f_K}\}$ 表示振幅， $\{f_1, \dots, f_K\}$ 是前 K 频率， $p_k = \lfloor \frac{T}{f_k} \rfloor, k \in \{1, \dots, K\}$ 表示相应的周期长度。对其他尺度下的多变量序列作同样的操作，这样，就能得到 $(M + 1) \times K$ 个周期间隔的序列。

步骤三：1D 到 2D 转换

参照 Timesnet 的思想，在利用 FFT 技术获得前 k 个频率及其对应的周期后，我们可以

将原本一整条的序列根据周期划分成对应的序列段, 然后再将相同的周期段叠加成二维的形状, 也就是重塑为二维图像。具体而言, 一维时间序列通过以下公式转化为二维张量:

$$\{Z_m^l\}_{m=0}^M = \{\text{Reshape}_{f_i, p_i}(\text{Padding}(x_m^l)) \mid m = 0, \dots, M; i = 1, \dots, K\} \quad (4)$$

其中 $\text{Padding}_{m,k}(\cdot)$ 表示通过在时间维度上用零扩展时间序列, f_i 和 p_i 分别表示转换后的 2D 张量的行数和列数。 $Z_m^l \in \mathbb{R}^{p_i \times f_i \times C}$ 表示基于频率 f_i 重塑的第 i 个时间序列, 其列和行分别代表对应周期长度 p_i 下的区间内变化和区间间变化。最终, 基于所选频率和估计周期, 我们获得一组 2D 张量 $\{Z_m^1, \dots, Z_m^K\}$, 这表明由不同周期导出了 k 种不同的时间 2D 变化。这种变换将两种类型的局部性引入到转换后的 2D 张量中, 即相邻时间点(列, 区间内变化)和相邻时期(行, 区间间变化)的局部性。因此, 时间 2D 变化可以很容易地通过 2D 核进行处理。

Module 2: 变量-尺度解耦重构

步骤一: 通道维度转换

在经过前两个模块的处理后, 我们获得了针对温室环境序列数据多尺度及多周期的分解, 即 $(C \times (M \times K))$, C 组变量, M 个尺度, 每个尺度下由 K 个二维张量组成, 如果将这样的图像组输入进后续模型, 就需要在处理完尺度融合后再考虑变量之间的耦合关系, 显得十分复杂。产生这一问题的点就在于变量通道和尺度通道没有分离。进一步的, 如果不对其做处理, 直接输入到后续的 2D 卷积模块, 每个通道的输入是 K 个形状不同的二维张量, 难以处理。

因此, 在输入到卷积模块之前, 需要通道维度转换模块。我们只需要将变量通道和尺度通道分离开来, 不去处理 C 个变量、每个变量都有 M 个尺度的情况, 而是转而处理 M 个尺度、每个尺度下有 C 个变量的情况, 这样的话由卷积模型去处理多变量的关系, 最终做一个多尺度融合就好。

具体而言, 本模块主要是将 $(C \times (M \times K))$ 的输入转换成 $(M \times (K \times C))$ 的形状, 如下图 2 及公式所示:

$$\begin{aligned} & \{[A_m^k \mid k = 0, \dots, K], [B_m^k \mid k = 0, \dots, K], \dots, [C_m^k \mid k = 0, \dots, K] \mid m = 0, \dots, M\} = \\ & \left\{ \begin{pmatrix} A_{m=0}^{k=1} & A_{m=0}^{k=2} & \dots & A_{m=0}^{k=K} \\ A_{m=1}^{k=1} & A_{m=1}^{k=2} & \dots & A_{m=1}^{k=K} \\ \vdots & \vdots & \ddots & \vdots \\ A_{m=M}^{k=1} & A_{m=M}^{k=2} & \dots & A_{m=M}^{k=K} \end{pmatrix}, \begin{pmatrix} B_{m=0}^{k=1} & B_{m=0}^{k=2} & \dots & B_{m=0}^{k=K} \\ B_{m=1}^{k=1} & B_{m=1}^{k=2} & \dots & B_{m=1}^{k=K} \\ \vdots & \vdots & \ddots & \vdots \\ B_{m=M}^{k=1} & B_{m=M}^{k=2} & \dots & B_{m=M}^{k=K} \end{pmatrix}, \dots, \begin{pmatrix} C_{m=0}^{k=1} & C_{m=0}^{k=2} & \dots & C_{m=0}^{k=K} \\ C_{m=1}^{k=1} & C_{m=1}^{k=2} & \dots & C_{m=1}^{k=K} \\ \vdots & \vdots & \ddots & \vdots \\ C_{m=M}^{k=1} & C_{m=M}^{k=2} & \dots & C_{m=M}^{k=K} \end{pmatrix} \right\} \\ & \Downarrow \\ & \left\{ \begin{pmatrix} A_{m=0}^{k=1} & B_{m=0}^{k=1} & \dots & C_{m=0}^{k=1} \\ A_{m=0}^{k=2} & B_{m=0}^{k=2} & \dots & C_{m=0}^{k=2} \\ \vdots & \vdots & \ddots & \vdots \\ A_{m=0}^{k=K} & B_{m=0}^{k=K} & \dots & C_{m=0}^{k=K} \end{pmatrix}, \begin{pmatrix} A_{m=1}^{k=1} & B_{m=1}^{k=1} & \dots & C_{m=1}^{k=1} \\ A_{m=1}^{k=2} & B_{m=1}^{k=2} & \dots & C_{m=1}^{k=2} \\ \vdots & \vdots & \ddots & \vdots \\ A_{m=1}^{k=K} & B_{m=1}^{k=K} & \dots & C_{m=1}^{k=K} \end{pmatrix}, \dots, \begin{pmatrix} A_{m=M}^{k=1} & B_{m=M}^{k=1} & \dots & C_{m=M}^{k=1} \\ A_{m=M}^{k=2} & B_{m=M}^{k=2} & \dots & C_{m=M}^{k=2} \\ \vdots & \vdots & \ddots & \vdots \\ A_{m=M}^{k=K} & B_{m=M}^{k=K} & \dots & C_{m=M}^{k=K} \end{pmatrix} \right\} \\ & = \{[A_0^k, B_0^k, \dots, C_0^k], [A_1^k, B_1^k, \dots, C_1^k], \dots, [A_M^k, B_M^k, \dots, C_M^k] \mid k = 0, \dots, K\} \quad (5) \end{aligned}$$

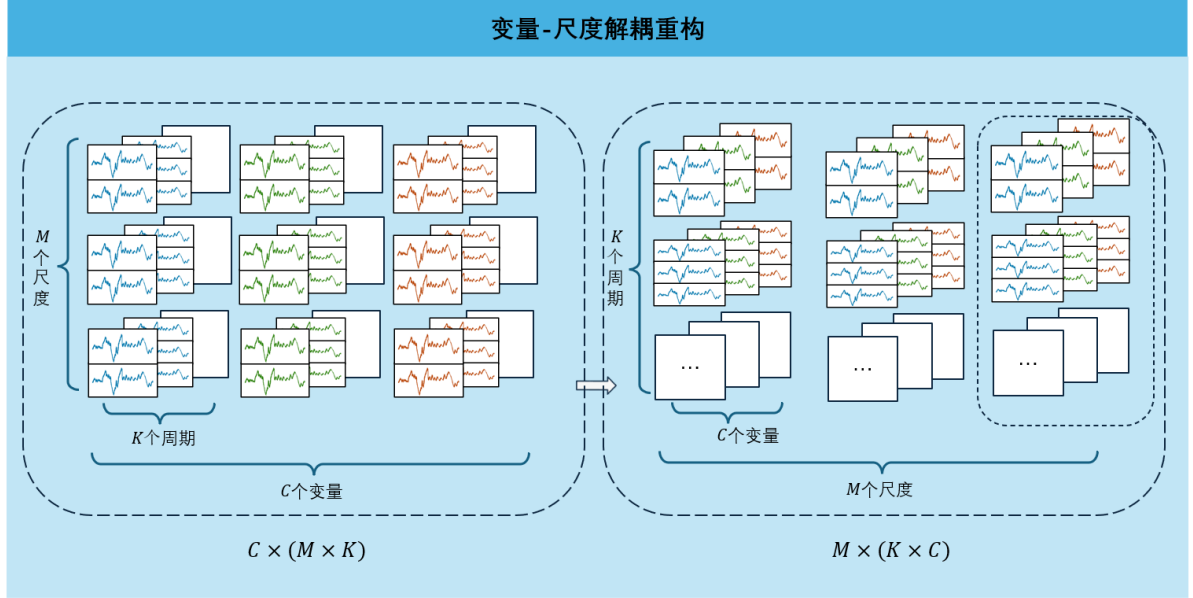


图 2 变量-尺度解耦重构模块

Module 3: 2D 深度可分离卷积

在将每个尺度下的多变量一维时间序列转换为多个二维张量后，模型需要一个高效的卷积模块来提取这些二维表征中的深层模式。传统的二维卷积在处理多通道输入时，计算成本和参数量较大，这对于需要快速响应的温室调控系统而言是一个挑战。因此，本模块引入了2D 深度可分离卷积（2D Depthwise Separable Convolution），它在保持甚至提升特征提取能力的同时，显著降低了模型的计算复杂度和参数数量。模型图如图 3 所示。

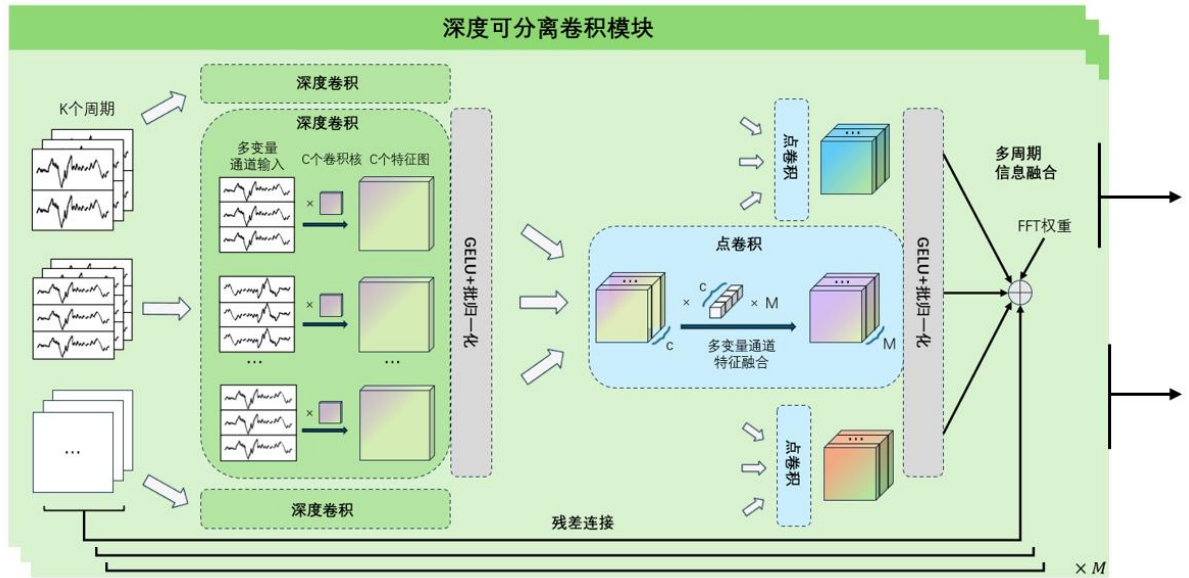


图 3. 2D 深度可分离卷积模块

2D 深度可分离卷积将标准卷积操作分解为两个独立的步骤，即深度卷积和逐点卷积。

经过通道维度转换模块后，在某一尺度 m 下，我们得到的输入为 $Z'_m \in \mathbb{R}^{K \times C \times P \times F}$ ，其中 K 是周期数量， C 是变量通道数量， P 和 F 分别是 2D 张量的行数和列数。为简化

表示，我们考虑对其中一个周期的 2D 张量 $Z_{mk} \in \mathbb{R}^{C \times P \times F}$ 进行处理。

步骤一：通道内时空模式提取（深度卷积）

此步骤负责捕捉每个输入通道（即每个环境变量在特定周期下的 2D 表征）内部的时空模式。它为每一个输入通道应用一个独立的 2D 卷积核。例如，对于由温度数据转换而来的 2D 张量，深度卷积会独立地提取其周期内（行）和周期间（列）的局部变化模式，而不考虑与其他变量（如湿度、CO₂）的交互。具体而言，该操作对输入的 C 个通道分别使用 C 个独立的卷积核 $W_d \in \mathbb{R}^{C \times 1 \times k_h \times k_w}$ （其中 k_h 和 k_w 是卷积核高和宽）进行卷积。对于第 c 个通道，其计算如下：

$$\hat{G}_c = \text{BatchNorm}(\sigma(\text{Conv2D}(Z_{mk,c}, W_{d,c}))), \quad c = 1, \dots, C \quad (6)$$

其中 $Z_{mk,c}$ 是输入的第 c 个通道， $W_{d,c}$ 是专门用于该通道的深度卷积核， σ 表示激活函数 GELU (Hendrycks 和 Gimpel, 2016 年)， BatchNorm 表示批归一化操作， \hat{G}_c 是输出的第 c 个通道特征图。这一步的输出为 $\hat{G} \in \mathbb{R}^{C \times P' \times F'}$ 。

步骤二：跨通道特征融合（逐点卷积）

在深度卷积完成对各通道内部特征的提取后，逐点卷积（本质上是一个 1×1 的卷积）负责在通道维度上进行特征融合。它通过对深度卷积输出的每个像素点上的所有通道值进行线性组合，实现不同环境变量特征的有效混合。这种跨通道的信息交互对于理解温室环境中各变量之间的耦合关系至关重要。

该操作使用 C_{out} 个 1×1 的卷积核 $W_p \in \mathbb{R}^{C_{out} \times 1 \times 1}$ 对深度卷积的输出 \hat{G} 进行处理，以实现通道间的特征融合与维度变换。

$$Y_{mk} = \text{BatchNorm}(\sigma(\text{Conv2D}(\hat{G}, W_p))) \quad (7)$$

最终输出 $Y_{mk} \in \mathbb{R}^{C_{out} \times P' \times F'}$ 是一个融合了多变量信息的 2D 特征图。

步骤三：多周期特征融合

上述的两步卷积是针对 K 个周期来说的，在每一个由 FFT 获得的周期上都要进行以变量为通道的深度可分离卷积，最终得到的结果也是某一周期下的特征图，需要将不同周期期间的信息融合，同时要考虑周期间的重要性。这可以通过 FFT 的结果实现，振幅 A 可以反映所选频率和时段的相对重要性，从而对应于每个变换的 2D 张量的重要性。因此，我们根据振幅来聚合 1D 表示，当然在使用这个权重之前，需要先将卷积后的结果按照之前得到的 f_i 和 p_i 展平：

$$X_m^l = \text{Reshape}_{f_i, p_i}(Y_{mk}), \quad i = 1, \dots, K \quad (8)$$

$$\{\hat{A}_{f_k}\}_{k=1}^K = \text{Softmax}(\{\hat{A}_{f_k}\}_{k=1}^K) \quad (9)$$

$$x_m^l = \sum_{k=1}^K \hat{A}_{f_k} \circ X_m^l, \quad m = 0, \dots, M \quad (10)$$

其中 Softmax 用于归一化权重， \circ 表示逐元素乘法。

步骤四：多尺度特征融合

在经过上述多个模块后，我们获得了多尺度过去信息 $\mathcal{X}^L = \{x_0^L, \dots, x_M^L\}$ 。由于不同尺度的序列呈现出不同的主导变化，它们的预测也呈现出不同的能力。为了充分利用多尺度信息，我们提出从多尺度序列中聚合预测，表示为：

$$\hat{x}_m = \text{Head}_m(x_m^L), m = 0, \dots, M \quad (11)$$

$$\hat{x} = \sum_{m=0}^M \hat{x}_m \quad (12)$$

其中 $\hat{x}_m \in \mathbb{R}^{H \times C}$ 代表第 m 个尺度序列的未来预测，最终输出为 $\hat{x} \in \mathbb{R}^{H \times C}$ ， H 代表要预测的时间步数， $\text{Head}_m(\cdot)$ 表示第 m 个尺度序列的预测头，由线性层组成。